

最优化理论作业参考答案¹

Question 1. (Problem 2.16, *Convex Optimization*)

Show that if S_1 and S_2 are convex sets in $R^{m \times n}$, then so is their partial sum

$$S = \{(x, y_1 + y_2) | x \in R^m, y_1, y_2 \in R^n, (x, y_1) \in S_1, (x, y_2) \in S_2\}. \quad (1)$$

解:

考虑两个点 $(\hat{x}, \hat{y}_1 + \hat{y}_2), (\tilde{x}, \tilde{y}_1 + \tilde{y}_2) \in S$, 也即

$$(\hat{x}, \hat{y}_1) \in S_1, \quad (\hat{x}, \hat{y}_2) \in S_2, \quad (\tilde{x}, \tilde{y}_1) \in S_1, \quad (\tilde{x}, \tilde{y}_2) \in S_2. \quad (2)$$

对任意 $0 \leq \theta \leq 1$,

$$\theta(\hat{x}, \hat{y}_1 + \hat{y}_2) + (1 - \theta)(\tilde{x}, \tilde{y}_1 + \tilde{y}_2) = (\theta\hat{x} + (1 - \theta)\tilde{x}, \theta\hat{y}_1 + (1 - \theta)\tilde{y}_1 + \theta\hat{y}_2 + (1 - \theta)\tilde{y}_2). \quad (3)$$

由 S_1 和 S_2 的凸性

$$(\theta\hat{x} + (1 - \theta)\tilde{x}, \theta\hat{y}_1 + (1 - \theta)\tilde{y}_1) \in S_1, \quad (4)$$

$$(\theta\hat{x} + (1 - \theta)\tilde{x}, \theta\hat{y}_2 + (1 - \theta)\tilde{y}_2) \in S_2. \quad (5)$$

因此

$$\theta(\hat{x}, \hat{y}_1 + \hat{y}_2) + (1 - \theta)(\tilde{x}, \tilde{y}_1 + \tilde{y}_2) \in S, \quad (6)$$

从而 S 是一个凸集。

¹感谢王箬同学的 Tex 模板和作业参考。

Question 2. (Problem 3.3, *Convex Optimization*)

Inverse of an increasing convex function. Suppose $f: R \rightarrow R$ is increasing and convex on its domain (a, b) . Let g denote its inverse, i.e., the function with domain $(f(a), f(b))$ and $g(f(x)) = x$ for $a < x < b$. What can you say about convexity or concavity of g ?

g 是凹函数

解:

g 的定义域 $(f(a), f(b))$ 显然是凸集。

考虑 $y_1, y_2 \in (f(a), f(b))$, 定义 x_1, x_2 为

$$x_1 = g(y_1), \quad x_2 = g(y_2), \quad (7)$$

根据逆函数的定义, 我们有

$$y_1 = f(x_1), \quad y_2 = f(x_2). \quad (8)$$

从 f 的凸性得

$$\theta f(x_1) + (1 - \theta)f(x_2) \geq f(\theta x_1 + (1 - \theta)x_2). \quad (9)$$

从 f 的单调性得, $x_1 \leq x_2$ 当且仅当 $f(x_1) \leq f(x_2)$, 也即 $g(y_1) \leq g(y_2)$ 当且仅当 $y_1 \leq y_2$, 这意味着 g 是单调增函数。

考虑任意 $0 \leq \theta \leq 1$

$$g(\theta y_1 + (1 - \theta)y_2) = g(\theta f(x_1) + (1 - \theta)f(x_2)) \quad (10)$$

$$\geq g(f(\theta x_1 + (1 - \theta)x_2)) \quad (11)$$

$$= \theta x_1 + (1 - \theta)x_2 \quad (12)$$

$$= \theta g(y_1) + (1 - \theta)g(y_2), \quad (13)$$

因此 g 是凹函数。

注意: 本题题干没有说明 f 的可微性, 因此不能使用凸函数的一阶或二阶条件来证明 g 的凹凸性。但在 f 二阶可导时使用二阶条件证明比较简洁, 下面给出在 f 二阶可导时的一种推导过程, 供参考。

解: (二阶条件)

因为 $g(f(x)) = x \Rightarrow f(g(x)) = x, g(x) \in [a, b]$, 对其求一阶导数得到 $f'(g(x))g'(x) = 1$, 变形成

$$f'(g(x)) = \frac{1}{g'(x)} \quad (14)$$

因为 $f(x)$ 在定义域内是单调递增的, 所以 $f'(x) > 0, x \in [a, b]$ 恒成立。推断 $g'(x) > 0$

对等式 14 再次求导

$$f''(g(x))g'(x) = -\frac{g''(x)}{g'^2(x)} \Rightarrow f''(g(x)) = -\frac{g''(x)}{g'^3(x)} \quad (15)$$

这里因为 f 是一个凸函数, 因此 $f''(x) \geq 0, x \in [a, b]$ 恒成立, 由此可以推断出 $g''(x) < 0$, 因此 g 是一个凹函数。

Question 3. 一范数规范化最小二乘问题

考虑一范数规范化最小二乘问题

$$\min_x \frac{1}{2} \|Ax - y\|^2 + \lambda \|x\|_1 \quad (16)$$

其中 $x \in R^n, A \in R^{m \times n}, y \in R^m, \lambda \in R_+$, 存在 λ_{\max} 使得, 当 $\lambda > \lambda_{\max}$ 时, 上述优化问题的最优解一定是 $x = 0$

解:

定义 $f(x) = \frac{1}{2} \|Ax - y\|^2 + \lambda \|x\|_1$, 则 $f(x)$ 的次梯度为 $A^T(Ax - y) + \lambda \partial \|x\|_1$ 。由一阶最优性条件, 某个点 x 为最优点的条件为:

$$0 \in A^T(Ax - y) + \lambda \partial \|x\|_1. \quad (17)$$

由次梯度的定义, 一范数的次梯度的第 i 维 $[\partial \|x\|_1]_i$ 为

$$[\partial \|x\|_1]_i = \begin{cases} 1, & x_i > 0, \\ [-1, 1], & x_i = 0, \\ -1, & x_i < 0, \end{cases} \quad i \in [1, n]. \quad (18)$$

由式子(17)和(18)得, 只需要令 $A^T y \in \lambda \partial \|0\|_1$ 就可以使 $x = 0$ 称为优化问题的最优解。此时若

$$-\lambda \leq [A^T y]_i \leq \lambda, \quad (19)$$

则条件 $A^T y \in \lambda \partial \|x\|_1$ 成立。从而得到最优解是 $x = 0$ 。此时只需满足 $\lambda_{\max} = \|A^T y\|_{\infty}$ 即可, 即 λ_{\max} 为 $A^T y$ 绝对值最大的元素的绝对值。

注 1: 有同学使用证明 0 是临近点梯度法一个稳定点的方法得出了相同的结论, 但这种方法是不对的: 优化问题最优解的性质不应该与具体的优化方法相关。

注 2: 本题要求只需给出 $\lambda_{\max} = \|A^T y\|_{\infty}$ 。事实上, 当 $\lambda \geq \lambda_{\max}$ 时, 0 是一个 (可能不唯一的) 最优解, 当 $\lambda > \lambda_{\max}$ 时, 0 是唯一解。部分同学同时证明了证明解的唯一性, 因此此处也给出一个证明供参考。

证: 定义 $g(z) = \frac{1}{2} \|z - y\|^2$, 以及 $f(x) = \frac{1}{2} \|Ax - y\|^2 + \lambda \|x\|_1 = g(Ax) + \lambda \|x\|_1$ 。

记 x^* 为 $f(x)$ 某一个最优解, 同时定义 f^* 为最优值, 即 $f(x^*) = f(0) = f^*$ 。

我们先证 $Ax^* = 0$ 。用反证法, 若 $Ax^* \neq 0$, 注意到 $g(z)$ 是严格凸的函数, $\|x\|_1$ 为凸函数, 这意味着对任意 $0 < \theta < 1$,

$$f(\theta x^* + (1 - \theta)0) = g(A(\theta x^* + (1 - \theta)0)) + \lambda \|\theta x^* + (1 - \theta)0\|_1 \quad (20)$$

$$< \theta g(Ax^*) + (1 - \theta)g(A0) + \theta \lambda \|x^*\|_1 + (1 - \theta)\lambda \|0\|_1 \quad (21)$$

$$= \theta f(x^*) + (1 - \theta)f(0) \quad (22)$$

$$= f^*, \quad (23)$$

与 f^* 为函数的最小值矛盾, 因此 $Ax^* = 0$ 。

再证 $x^* = 0$ 。注意到

$$f(x^*) - f(0) = g(Ax^*) - g(A0) + \lambda \|x^*\|_1 - \lambda \|0\|_1 = \lambda (\|x^*\|_1 - \|0\|_1), \quad (24)$$

但 $f(x^*) - f(0) = 0$, 因此当 $\lambda > \lambda_{max} \geq 0$ 时, $\|x^*\|_1 = \|0\|_1 = 0$, 即 $x^* = 0$ 。

当 $\lambda = \lambda_{max}$ 时, 解有可能不唯一, 例如当 $\lambda = \lambda_{max} = 0$ 时, 所有令 $Ax = 0$ 的非零 x 都是原问题的最优解。